

Progetto Finale di Machine Learning: Tracce e Consegne

Traccia 1: Kaggle Playground Series (A scelta)

Questa traccia vi permette di misurarvi con una competizione reale sulla piattaforma Kaggle, scegliendo un problema basato su dati tabulari.

Obiettivo: Selezionare una competizione della serie Kaggle Playground (es. Spaceship Titanic, Bank Churn, ecc.).

Vincoli: Sono vietate le competizioni "Featured" che richiedono eccessiva potenza di calcolo o l'uso di cluster GPU esterni. Il progetto deve essere completabile con risorse hardware standard (es. Google Colab o laptop personale).

Cosa fare: Analisi esplorativa dei dati (EDA), pulizia del dataset, confronto tra almeno tre modelli (es. Random Forest, XGBoost, CatBoost) e invio della sottomissione finale per ottenere lo score sulla leaderboard.

Traccia 2: Classificazione di Immagini con Neural Network (CIFAR-10)

In questo progetto dovrete costruire un modello di Deep Learning capace di riconoscere oggetti e animali in immagini a bassa risoluzione.

Dataset: CIFAR-10 (60.000 immagini 32x32 pixel divise in 10 classi: aerei, automobili, uccelli, gatti, cervi, cani, rane, cavalli, navi e camion).

Obiettivo: Implementare una rete neurale (CNN) e ottimizzarne le performance.

Cosa fare: * Preprocessing e normalizzazione dei pixel.

Definizione dell'architettura (livelli convoluzionali, pooling, ecc.).

Utilizzo di tecniche di regolarizzazione (Dropout, Batch Normalization) e Data Augmentation per prevenire l'overfitting.

Analisi dei risultati tramite matrice di confusione e curve di loss/accuracy.

Traccia 3: Regressione Avanzata - Ames Housing Dataset

Dimenticate il California Housing: in questa traccia affronterete il dataset di Ames (Iowa), una sfida di Machine Learning classico molto più complessa e ricca di variabili.

Dataset: House Prices: Advanced Regression Techniques (Kaggle). Il dataset contiene 79 variabili esplicative che descrivono quasi ogni aspetto delle abitazioni residenziali.

Obiettivo: Prevedere il prezzo di vendita finale delle case.

Cosa fare: * Feature Engineering: Questa è la parte core. Dovrete gestire 79 colonne, molti dati mancanti (Missing Values) e variabili categoriche complesse (Ordinal vs Nominal encoding).

Modellazione: Implementare modelli di regressione robusti. È richiesto l'uso di modelli regolarizzati come Ridge o Lasso, o ensemble come Gradient Boosting.

Validazione: Valutare il modello utilizzando il logaritmo dell'errore quadratico medio (RMSE) tra il valore previsto e quello reale